

Otimização da Alocação de Orçamento de Marketing

Maximização do lucro entre dois canais de mídia com retorno marginal decrescente, via gradiente e critério da Hessiana.

Equipe	Felipe Brazão · Gabriel Goes · Felipe Liborio
Data	Belém, junho de 2026
Repositório	projeto-otimização (full stack: FastAPI + SymPy + React)

Resumo

Este trabalho parte de um problema real de marketing digital — como dividir um orçamento entre canais de mídia que apresentam retorno decrescente — e o modela como a maximização de uma função de duas variáveis $L(x, y)$. Calculamos o gradiente, resolvemos $\nabla L = 0$ para obter o ponto crítico em forma fechada e o classificamos como máximo global pelo critério da Hessiana. Em seguida, entregamos uma aplicação full stack que automatiza todo o processo para uma persona não especialista, exibindo a recomendação, a superfície 3D do lucro e uma explicação acessível de como a solução foi obtida.

1. Prospeção do Problema (PBL)

Referência

Yang, Y., Feng, B., Salminen, J., & Jansen, B. J. (2022). Optimal advertising for a generalized Vidale–Wolfe response model. *Electronic Commerce Research*, 22(4), 1275–1305. DOI: 10.1007/s10660-021-09468-x. Springer Nature.

Artigo revisado por pares cujos experimentos usam dados reais de campanhas de e-commerce no Google AdWords, Facebook Ads e Baidu Ads.

Recorte

“As the total budget increases, the resulting payoff (...) increases monotonically, but the ROI decreases, which is consistent with the law of diminishing marginal utility.” — Yang et al. (2022).

O artigo evidencia que a curva de resposta da publicidade é côncava: cada real adicional investido em um canal gera menos receita incremental que o anterior. É essa concavidade que garante a existência de um ponto de investimento ótimo.

Justificativa

O problema é adequado à disciplina porque: (i) a verba é dividida entre dois ou mais canais, gerando uma função objetivo de várias variáveis; (ii) o retorno marginal decrescente se traduz em concavidade, garantindo Hessiana negativa definida e máximo global interior; (iii) a condição de otimalidade do artigo (igualar o retorno marginal entre canais) é exatamente a solução do sistema $\nabla L = 0$; e (iv) é uma dor concreta de uma persona realista. Para manter o escopo de otimização estática, adotamos a versão estática e côncava do modelo dinâmico do artigo, preservando a essência econômica (diminishing returns).

2. Persona e Contexto

Rafaela Mendes, 31 anos, analista de marketing digital de um e-commerce de moda (faturamento ~R\$ 600 mil/mês). Há quatro anos cuida da mídia paga e administra um orçamento mensal de R\$ 40 mil, dividido principalmente entre Google Ads e Instagram Ads. Tem desenvoltura com planilhas, mas não tem formação em cálculo.

Dor

Hoje ela decide a divisão da verba “no feeling” e por tentativa e erro. Como cada canal satura, ela acaba investindo demais no canal saturado e de menos no que ainda renderia — desperdiçando verba — e não consegue justificar a alocação para a diretoria com números.

Métricas de sucesso

Indicador	Atual	Meta com o sistema
Lucro líquido da mídia paga	linha de base	+10% a +15%

Verba desperdiçada em canal saturado	15–20% do orçamento	< 5%
Tempo para decidir a alocação	~4 horas	< 5 minutos
Decisões justificáveis à diretoria	0% (intuição)	100%

Impacto esperado

Rafaela insere quatro parâmetros que já conhece do histórico das campanhas e recebe, em segundos, quanto investir em cada canal (x^* , y^*), o lucro ótimo esperado e a garantia matemática de que é um máximo. A seção “Como foi obtido” dá a ela uma narrativa pronta para defender a decisão na reunião — substituindo o “feeling” por um critério ótimo reproduzível mês a mês.

3. Modelagem Matemática

3.1. Variáveis de decisão e parâmetros

x = investimento no canal A (Google Ads), em milhares de R\$, $x \geq 0$.

y = investimento no canal B (Instagram Ads), em milhares de R\$, $y \geq 0$.

a_1, a_2 = retorno marginal inicial de cada canal ($a_i > 1$, para que o canal cubra o custo unitário do investimento).

b_1, b_2 = coeficiente de saturação de cada canal ($b_i > 0$, garante a concavidade da receita).

3.2. Função objetivo

A receita de um canal com investimento t modela o retorno decrescente como uma parábola côncava:

$$R(t) = a_i \cdot t - b_i \cdot t^2$$

O retorno marginal $R'(t) = a_i - 2b_i \cdot t$ decresce com t (cada real rende menos que o anterior). Considerando que 1 R\$ investido custa 1 R\$, o lucro total é a receita dos dois canais menos o custo:

$$L(x, y) = (a_1 \cdot x - b_1 \cdot x^2) + (a_2 \cdot y - b_2 \cdot y^2) - (x + y)$$

3.3. Domínio e restrições

Domínio: $D = \{ (x, y) \in \mathbb{R}^2 : x \geq 0, y \geq 0 \}$. Não se investe valor negativo. Com $a_i > 1$ e $b_i > 0$, o ponto crítico cai no interior do domínio ($x^*, y^* > 0$), de modo que não há necessidade de checar a fronteira.

3.4. Derivadas parciais e gradiente

Derivando L em relação a cada variável:

$$\partial L / \partial x = a_1 - 2b_1 \cdot x - 1 \quad \partial L / \partial y = a_2 - 2b_2 \cdot y - 1$$

$$\nabla L = (a_1 - 2b_1 \cdot x - 1, a_2 - 2b_2 \cdot y - 1)$$

3.5. Ponto crítico (anulando o gradiente)

Igualando cada componente do gradiente a zero, o sistema é desacoplado e tem solução única em forma fechada:

$$x^* = (a_1 - 1) / (2b_1) \quad y^* = (a_2 - 1) / (2b_2)$$

3.6. Hessiana e classificação

A matriz Hessiana das segundas derivadas é constante (não depende de x, y):

$$H = \begin{bmatrix} -2b_1 & 0 \\ 0 & -2b_2 \end{bmatrix}$$

Os autovalores são $\lambda_1 = -2b_1$ e $\lambda_2 = -2b_2$. Como $b_i > 0$, ambos são estritamente negativos $\Rightarrow H$ é negativa definida em todo o plano $\Rightarrow L$ é estritamente côncava $\Rightarrow$ o único ponto crítico (x^*, y^*) é um máximo global. Não há máximos locais concorrentes nem fronteira a verificar.

3.7. Valor ótimo e sensibilidade

Substituindo o ponto crítico em L :

$$L(x^*, y^*) = (a_1 - 1)^2 / (4b_1) + (a_2 - 1)^2 / (4b_2)$$

A análise de sensibilidade (Teorema do Envelope) mostra que $\partial L^* / \partial a_1 = x^*$: um aumento marginal no retorno inicial de um canal eleva o lucro ótimo na proporção do investimento ótimo naquele canal. O lucro cresce com a_i (canal mais produtivo) e decresce com b_i (canal que satura mais rápido).

4. Exemplo Numérico e Interpretação

Com os parâmetros estimados pela persona — $a_1 = 10$, $b_1 = 0.5$, $a_2 = 8$, $b_2 = 0.4$ — obtemos:

Grandeza	Cálculo	Resultado
Investir no canal A (x^*)	$(10 - 1) / (2 \cdot 0.5)$	9.00 (mil R\$)
Investir no canal B (y^*)	$(8 - 1) / (2 \cdot 0.4)$	8.75 (mil R\$)
Lucro ótimo $L(x^*, y^*)$	$40.5 + 30.6$	71.125 (mil R\$)
Autovalores da Hessiana	$-2 \cdot 0.5$; $-2 \cdot 0.4$	-1 ; -0.8 (< 0)

Interpretação: a persona deve investir R\$ 9.000 no canal A e R\$ 8.750 no canal B, gerando um lucro líquido de aproximadamente R\$ 71.125. Como ambos os autovalores são negativos, o sistema garante que essa é a melhor alocação possível — qualquer deslocamento reduz o lucro. Investir mais no canal A o levaria à saturação; investir mais no B desperdiçaria verba que rende mais no A.

5. Implementação (Full Stack)

O sistema segue o fluxo: a persona insere os parâmetros no front end → o back end calcula a solução ótima → o front end exibe a recomendação e a justificativa.

Back end — FastAPI + SymPy

O endpoint POST /otimizar recebe (a_1, b_1, a_2, b_2) , validados por Pydantic ($a_i > 1$, $b_i > 0$). O módulo optimizer.py usa SymPy para derivar simbolicamente $\partial L / \partial x$ e $\partial L / \partial y$, resolver o sistema $\nabla L = 0$, montar a Hessiana e classificá-la pelos autovalores (NumPy). Retorna x^* , y^* , $L(x^*, y^*)$, receita, custo, a Hessiana, os autovalores, a classificação e a lista de passos legíveis. Um segundo endpoint /superfície gera a malha 3D do lucro. A corretude é garantida por 8 testes pytest (forma fechada do ótimo, classificação, simetria da Hessiana e validação de entrada).

Front end — React + Tailwind + Plotly

Interface em que a persona preenche os quatro parâmetros e visualiza: (i) a recomendação em cartões — quanto investir em cada canal e o lucro ótimo, formatados em R\$; (ii) a superfície 3D do lucro com o ponto ótimo destacado; e (iii) a seção “Como foi obtido”, que lista os passos matemáticos retornados pelo back end. Nenhum conhecimento de cálculo é exigido do usuário.

6. Como a Solução foi Obtida (versão acessível)

Cada canal de marketing rende cada vez menos à medida que recebe mais dinheiro (satura). O “ponto ótimo” é aquele em que o último real investido em A rende o mesmo que o último real investido em B — daí em diante, mover verba de um para o outro só piora o resultado. Matematicamente, isso acontece onde as duas inclinações do lucro (as derivadas parciais) são zero ao mesmo tempo. Resolvendo essa condição chegamos a x^* e y^* . O teste da Hessiana confirma que é um pico (e não um vale ou uma sela): como a curva é “arqueada para baixo” nas duas direções, o ponto encontrado é o de lucro máximo.

7. Declaração de Uso de IA

Ferramentas de IA (Claude) foram usadas como apoio para redação e revisão de texto, scaffolding inicial do código e dos testes, e localização/formatação da referência bibliográfica. A modelagem matemática foi conferida manualmente pela equipe e os resultados numéricos são validados pelos testes automatizados. Nenhum conteúdo foi entregue sem revisão humana.

Referências

- Yang, Y., Feng, B., Salminen, J., & Jansen, B. J. (2022). Optimal advertising for a generalized Vidale–Wolfe response model. *Electronic Commerce Research*, 22(4), 1275–1305. <https://doi.org/10.1007/s10660-021-09468-x>
- Stewart, J. Cálculo, Volume 2. (funções de várias variáveis, derivadas parciais, gradiente e máximos/mínimos — critério da Hessiana).